

Материалы кафедры ММП факультета ВМК МГУ. Введение в глубокое обучение.

Занятие 08. Свёрточные архитектуры

Занятие провел: Оганов Александр
(@we1mud)

Материалы составил: Оганов Александр
(@we1mud)

Материалы основаны на лекции
Садртдинова Ильдуса Рустемовича

Москва, Весенний семестр 2026

Источники:

- Лекция Садртдинова Ильдуса Рустемовича на курсе "Введение в глубокое обучение" факультета ФКН
- **LeNet**: [Yann LeCun et al., 1998](#), примерно 84 тысячи цитирований
- **ImageNet**: [O.Russakovsky et al., 2015](#), примерно 49 тысяч цитирований
- **AlexNet**: [Krizhevsky et al., 2012](#), примерно 150 тысяч цитирований
- **VGG**: [Simonyan and Zisserman, 2014](#), примерно 160 тысяч цитирований
- **GoogLeNet (a.k.a. Inception)**: [Szegedy et al., 2014](#), примерно 71 тысяча цитирований
- **ResNet**: [He et al., 2015](#), примерно 310 тысяч цитирований

- Ландшафт функции потерь при skip connections: [Hao Li et al., 2017](#), примерно 3 тысячи цитирований
- [Ландшафты функций потерь](#)
- Ансамблирование в skip connections: [Veit et al., 2016](#), примерно 1500 цитирований
- **DenseNet**: [Huang et al., 2016](#), примерно 60 тысяч цитирований
- **MobileNet**: [Howard et al., 2017](#), примерно 37 тысяч цитирований
- **NASNet**: [Zoph et al., 2017](#), примерно 9 тысяч цитирований
- **EfficientNet**: [Tan and Le, 2019](#), примерно 35 тысяч цитирований
- **ConvNet**: [Liu et al., 2022](#), примерно 12 тысяч цитирований

Это занятие будет посвящено развитию сверточных архитектур. Мы проследим, как проверялись различные гипотезы и как менялась область с течением времени, опираясь на ключевые статьи. Для каждой работы мы разберем, какую проблему она решала, обсудим роль бенчмарков, а также идеи, которые впоследствии перешли в другие области, и способы их интерпретации. Мы также затронем одну из самых важных идей для глубинного обучения – перенос знаний (transfer learning). Количество цитирований указано для того, чтобы дать представление о масштабе области и вовлеченности научного сообщества, а **не** для прямого сравнения статей друг с другом.


Свёрточные архитектуры

Разговаривать об архитектурах можно долго, много и сложно, но наша цель чуть другая. Мы не собираемся разобраться в каждой модели из зоопарка (действительно есть [model zoo](#)), мы хотим понять какие проблемы стояли и какие идеи позволили их решить или чуть схитрить.

Мы часто будем обращаться к **основному принципу** глубокого обучения: "чем больше слоев, тем лучше" или иными словами **stack more layers**.

Самая простая схема свёрточной сети для классификации

На прошлом занятии мы описали самую простую свёрточную архитектуру.



Источник

LeNet (1998)

Yann LeCun et al., 1998, примерно 84 тысячи цитирований

Первая свёрточная появилась достаточно давно и чем-то соответствовала схеме предложенной выше.

- Свёрточные слои и слои Subsampling (pooling)
- В качестве функций активации взяты Sigmoid
- В качестве головы полносвязные слои
- Работает для изображений фиксированного размера




Fig. 2. Architecture of LeNet-5, a Convolutional Neural Network, here for digits recognition. Each plane is a feature map, i.e. a set of units whose weights are constrained to be identical.

Вопрос: Какие проблемы вы видите?

Ответ:

Ответов может быть много, например:

- На входе изображения размера 32
- Будут затухать градиенты от Sigmoid
- Сразу происходит pooling, мы можем потерять информацию

Однако важно учитывать, что мы говорим про 1998 год. Кроме того, в статье решалась не просто задача распознавания цифр или букв по отдельности, а распознавание последовательности рукописных символов с различными эвристиками.

Выше мы предложили архитектуру, вроде бы, она даже выглядит разумно, теперь рассмотрим архитектуру **LeNet**, как нам понять, что лучше? Пусть в соседней лаборатории предложили новую архитектуру, как понять, насколько она хорошая?

Проблема: Мы не умеем сравнивать архитектуры между собой, необходима некая единая сложная задача с понятной метрикой качества, необходим **benchmark**. Сегодня мы будем говорить про область классификации изображений, однако, вопрос хороших бенчмарков во многих областях всё ещё не решён.

ImageNet


В 2012 году появился **ImageNet**, датасет, на котором каждый мог проверить модель. Подробнее описано в статье создателей [O.Russakovsky et al., 2015](#), примерно 49 тысяч цитирований.

Здесь и далее мы будем приводить число цитат **не с целью оценки качества статьи** (так как нельзя мерить научную ценность только по количеству цитат), а **с целью демонстрации, того как много людей развивало и вложили свои труды в эту область.**

ImageNet статистика

- 1000 классов
- ILSVRC-2012: 1.2M изображений (~150Gb)
- Сейчас уже более 14M изображений для решения разных задач: детекция, локализация, детекция по видео

Благодаря удобной инфраструктуре, открытому доступу получилось создать соревнование, в котором участвовали многие исследователи в области обработки изображений, тем самым оценивая свои идеи на едином бенчмарке. Возможно, именно благодаря **ImageNet** людям удалось так быстро решить **прикладные и фундаментальные проблемы DL.**




Результаты

Ниже представлены результаты, которые получались в разные годы, нам важно отметить **появление глубокого обучения** и почему резко **число слоев** увеличилось.

Именно об этом мы будем говорить дальше.

Важно, что оценка человеческой точности не совсем честная, так как время для определения было ограничено и классифицировать изображения редких животных бывает трудно. Не стоит забывать, что выбрать подходящий класс из возможных 1000 бывает трудно, как минимум, держать в памяти все возможные классы. Подробнее можно прочитать в оригинальной статье [O.Russakovsky et al., 2015](#).

Крайне интересный блог про анализ ошибок доступен по [ссылке](#), автор Андрей Карпатый.




[Источник](#)

AlexNet (2012)

[Krizhevsky et al., 2012](#), примерно 150 тысяч цитирований.

Впервые в истории DL попробовали обучить настолько большую сеть, которая даже не влезала на одну GPU, до этого люди сторонились огромных сетей и большого числа параметров.



В начале люди старались учить "глубокие" нейросети, но резко столкнулись с проблемой затухания градиентов, даже при правильных функциях активации. Кроме того, приходилось все изображения приводить к одному размеру, так как полносвязный слой имеет фиксированную размерность входа.

Большая часть вычислительных мощностей тратилась на свёрточные блоки, при этом большинство параметров содержалось в линейных слоях.

- Max pooling, в качестве функций активации ReLU
- Dropout и Аугментация изображений для уменьшения переобучения
- 5-6 дней на 2 NVIDIA GTX 580 3GB
- Работает для изображений фиксированного размера


	Top-1 Accuracy	Top-5 Accuracy	Num params
AlexNet	56.522	79.066	61M

Метрики здесь и далее взяты из реализаций [torchvision](#)

P.S. PyTorch появился в 2016 году, а TensorFlow в 2015. Открытый исходный код появился только спустя 5 лет, его можно найти в этом [GitHub](#).

VGG (2014)

[Simonyan and Zisserman, 2014](#), примерно 160 тысяч цитирований.



При обучении нейросети с глубиной 8 уже начинались проблемы, а обучить 19 слоев крайне трудно. При этом все в области понимали, что чем больше слоев, тем будет выше качество. В работе VGG предложили обучать не end-to-end, то есть не обучать всю нейросеть сразу.

Например, мы можем обучить сначала первые 5 слоев, потом следующие и так далее. При этом на первой стадии мы используем 5 слоев, а потом добавляем на них полносвязанную голову.

Вопрос: Какие проблемы вы видите в этом подходе?

Ответ:

Признаки, которые выучила модель на первой фазе, могут не подходить для второй, однако они почти не будут меняться из-за затухающих градиентов.

Кроме того, разные этапы обучения влекут разные гиперпараметры, что усложняет обучение и настройку модели.

В модели VGG стандартизировали все свёртки (все они с ядром размера 3), благодаря чему большая часть параметров хранится в свёрточных слоях, в отличие от AlexNet. Ядра с размером 3 требуют мало параметров, извлекают локальные признаки. Например, для достижения receptive field размера 5, мы можем взять 2 свёртки размера 3 (то есть 18 параметров) или одну свёртку размера 5 (25 параметров). В случае receptive field размера 11 эффективность оказывается еще заметнее.

- Visual Geometry Group (University of Oxford)
- Более глубокие сети: версии на 16 и 19 слоев

- Используются свёртки с ядром размера 3, привело к более эффективным вычислениям
- Проблема затухания градиентов привела к не end-to-end обучению
- Обучения стадиями
- 2-3 недели на 4 NVIDIA Titan Black GPU
- Работает для изображений фиксированного размера


	Top-1 Accuracy	Top-5 Accuracy	Num params
VGG-19	72.376	90.876	143.7M

P.S. Первый автор выпускник ВМК, [подробнее тут](#).

GoogLeNet (a.k.a Inception, 2014)

[Szegedy et al., 2014](#), примерно 71 тысяча цитирований.

Впервые была использована идея применения разных слоев к одному входу, в частности применение разных свёрток параллельно к одной feature map.




Вопрос Какая интуиция стоит за параллельным использованием свёрток к одному изображению?

Ответ:

Возможно, мы хотим извлечь из изображения как глобальные, так и локальные признаки, тогда нам нужно пройти одновременно как свёрткой с маленьким размером ядра, так и с более большим. В примере выше для глобальных свойств мы используем свёртки с ядром 5 и слои пуллинга.

С целью увеличения эффективности и уменьшения параметров используются свёртки с ядром размера 1, так как благодаря им получается уменьшить число каналов на вход свёрткам размера 3 и 5 (уменьшить число параметров в них).



- Параллельные вычислительные блоки (архитектура не последовательная)
- Использование свёрток с разными ядром для повышения эффективности
- Не end-to-end обучение, использование вспомогательных классификаторов
- Работает для изображений фиксированного размера


	Top-1 Accuracy	Top-5 Accuracy	Num params
GoogLeNet	69.778	89.530	6.6M

Residual (skip) connections (2015)


[He et al., 2015](#), примерно 310 тысяч цитирований (за 2025 год число цитирований увеличилось примерно на 50 тысяч).

Все подходы выше старались увеличить число слоев и по-разному решали проблему затухания градиентов, чаще всего мы отказывались от end-to-end обучения. В этом случае процесс обучения становился сильно сложнее.

В 2015 году появилась идея, которая поменяла подход к построению архитектур не только в компьютерном зрении, но и в других областях. Ниже представлена схема и **изначальная мотивация** к использованию **skip connections**, а именно решение проблемы затухания градиентов.




Ниже показан пример **skip connections** в блоке свёрточной сети.



ResNet (2015)

[He et al., 2015](#), примерно 310 тысяч цитирований (за 2025 год число цитирований увеличилось примерно на 50 тысяч).

Поход с использованием **skip connections** позволил обучать нейросети со **152 слоями**.



- **Residual connections** помогает течь градиентам лучше => можно брать сильно больше слоев!!! **stack MUCH MORE layers**
- Использование **batch normalization** для более стабильного обучения
- Вместо **pooling** слоев в блоках использовать свёртки с **stride=kernel_size** (как обсуждали ранее)
- **Global average pooling** то есть усреднение по размерности изображения (H и W) на последнем слое, на выходе получаем вектор размерности равным числу каналов => обработка изображений любых размеров

Важно: использование **batch normalization** тоже упрощает обучение более глубоких слоев, например, если добавить батч нормализацию к **VGG** можно обучать **end-to-**

end .

	Top-1 Accuracy	Top-5 Accuracy	Num params
ResNet-152	78.312	94.046	60.2M

Вопрос: Почему Global average pooling работает? Какая интуиция может быть?

Ответ:

Мы говорили, что обычно, каждый канал извлекает свои признаки.

Рассмотрим пример где у нас 2 канала, например, горизонтальные линии на канале 1, а вертикальные на канале 2. Значит усреднее по размерности изображения даст вектор размерности 2. Первая компонента хранит информацию о среднем числе горизонтальных линий, а вторая о вертикальных.

Если признаки достаточно сложные (а мы используем много слоев, значит они сложные), то мы сможем классифицировать изображения зная средние признаки по изображению.

Почему skip connections работают? (еще одно объяснение)

[Hao Li et al., 2017](#), примерно 3 тысячи цитирований.

Существуют отдельные направления исследования ландшафта функции потерь нейронной сети (зависимость ошибки от параметров модели). В работе [Hao Li et al., 2017](#) изобразили ландшафт функции потерь в архитектуре с skip connections и без них.




Figure 1: The loss surfaces of ResNet-56 with/without skip connections. The proposed filter normalization scheme is used to enable comparisons of sharpness/flatness between the two figures.


Область исследование ландшафтов функций потерь обычно называют **loss landscape**.

В области есть много интересных и важных работ и разнообразных визуализаций (пример).

Почему skip connections работают? (и ещё одно объяснение)

Veit et al., 2016, примерно 1500 цитирований.

Можно посмотреть на нейросети со skip connections как некоторый подход к ансамблированию Veit et al., 2016. Если расписать граф вычислений чуть аккуратней, то можно получить следующую картину:



Если мы считаем, что вход равен y_0 , тогда выход будет равен

$$\begin{aligned} y_3 &= y_2 + f_3(y_2) \\ &= [y_1 + f_2(y_1)] + f_3(y_1 + f_2(y_1)) = \\ &= [y_0 + f_1(y_0)] + f_2(y_0 + f_1(y_0)) + f_3(y_0 + f_1(y_0) + f_2(y_0 + f_1(y_0))). \end{aligned}$$

Такая запись чем-то напоминает градиентный бустинг, а по интуиции из машинного обучения мы знаем, что ансамблирование это хороший способ поднять качество.

Результаты

	Top-1 Accuracy	Top-5 Accuracy	Num params
AlexNet	56.522	79.066	61M
VGG-19	72.376	90.876	143.7M
GoogLeNet	69.778	89.530	6.6M
ResNet-152	78.312	94.046	60.2M

Что было дальше?

С появлением ResNet - 152 люди научились решать задачу классификации изображений точнее человека*. Следующая цель была заставить мощные


классификаторы работать на телефонах и без мощных GPU. Для этого попробовали много чего, но мы поговорим об этом кратко, так как у нас другие цели. Все желающие могут посмотреть подробнее в [источнике](#).

Зоопарк моделей:

- DenseNet [Huang et al., 2016](#): добавили **residual connections** между любыми двумя слоями
- MobileNet [Howard et al., 2017](#): подобрали определенные свёрточные блоки для эффективной реализации (использование свёрток с ядром размера 1)
- NASNet [Zoph et al., 2017](#): обучили умный перебор (Neural Architecture Search) всех возможных архитектур из заранее заданных блоков (об этом подробнее в следующем семестре)
- EfficientNet [Tan and Le, 2019](#): использовали NAS на блоках на специальных блоках, mobile NAS

Результаты 2019 года представлены на графике ниже, важно отметить, что рассматриваемые модели это именно свёрточные архитектуры.

*в специальных условиях, с некоторыми ограничениями по времени. Об этом было выше.



[Источник](#)

Не свёрточные модели

Текущая State-of-the-art (SOTA) в классификации изображений принадлежит трансформерам, но об этом мы поговорим в следующих лекциях. Не смотря, на проигрыш в качестве лучшей модели, свёрточные сети все еще очень популярны.

Основные **преимущества** свёрточных архитектур:

- Быстрее и проще учатся
- Более эффективные по вычислениям
- Хорошо работают на малых данных


Например, если вам нужно запустить модель компьютерного зрения на весах в продуктовом магазине, то что-то сложнее свёрточной сети будет дорого и сложно запустить в real-time.

Кроме того, свёрточные сети можно использовать для обработки аудио или иных числовых последовательностей. Также есть подходы и идеи, как сделать использовать идеи из трансформеров в свёрточных архитектурах, например ConvNet [Liu et al., 2022](#), примерно 12 тысяч цитирований.

Отметим, что идеи и знания, которые получили люди при решении задачи классификации изображений часто переносят и на текущие работы. Например, почти все современные архитектуры используют **skip connections**, а также встречаются методы не использующие **end-to-end** обучение.

Судьба ImageNet

К сожалению, со временем стало появляться все больше инженерных работ, в которых отсутствовали новые и интересные идеи. Люди стали гнаться за сотыми процентами и плодить кучу разных архитектур разной степени красоты. Ниже представлены основные результаты в области.




Transfer learning

Весь рассказ выше строился вокруг датасета `ImageNet` в котором более миллиона изображений. Часто не бывает в наличии настолько большой обучающей выборки, а обучать большие модели на маленьком объеме данных очень трудно и приводит к переобучению.

Для решения этой задачи существует подход `transfer learning`. Мы будем использовать уже предобученные модели в качестве при решении своей конкретной задачи (например, классификация листьев деревьев).

Pre-training (предобучение)


Для начала обучим модель на какой-то общей задаче (большом объеме данных, например, `ImageNet`). Мы предполагаем, что модель научилась извлекать признаки, которые хорошо обобщаются на схожие данные (например, на `Cifar10`). Так как модель не переобучилась и показывает хорошее качество на тесте, у нас есть надежда на обобщающую способность.



[Источник](#)

Linear probing

Далее возьмем предобученную модель и заморозим все веса. Мы уже знаем, что модель извлекла хорошие признаки, значит на них мы можем обучить MLP/линейный слой. Для этого мы заменим в модели линейный слой (так как число классов скорее всего поменялось), заморозим все остальные веса и будем обучать модель.




[Источник](#)

Finetuning

Мы также заменяем голову модели (линейный слой) с целью предсказания нужного числа классов, но будем обучать всю модель целиком. Идейно мы обучаемся не со случайной инициализации весов, а в окрестности какого-то "достаточно хорошего" минимума. Есть отдельные работы по исследованию минимумов и как именно нужно обучать модель в таком режиме.

Transfer learning: fine-tuning



Источник

Рассмотренные подходы можно комбинировать, например заморозить только первые слои, а обучать остальные и тому подобное.

Вопрос: В каком режиме обучения модель больше подвержена переобучению?

Вопрос: В каком режиме можно найти более хорошее решение задачи, то есть выбить выше качество?

Ответ:

Чем больше степеней свободы и параметров, тем вероятней переобучение, но тем выше итоговое качество. Значит linear probing меньше подвержен переобучению, но обычно сходится к более низкому качеству, чем fine-tuning, который вероятней может переобучиться (особенно если выборка маленькая).

Вопрос: Можно ли взять преимущества и fine-tuning и linear probing? Какие есть промежуточные решения?

Ответ:

Например, можно разморозить последние N слоев. Размораживать первые слои не имеет смысла, так как последующие ожидают на вход другие признаки.

В будущем мы рассмотрим методы эффективного fine-tuning (Parameter-Efficient Fine-Tuning/PEFT).

Заключение

- Модели, которые используют знания о данных (**Inductive bias**) работают

лучше

- Наличие и создание единых бэнчмарков позволяет области развиваться
- Методы и подходы из компьютерного зрения переиспользовались в других областях и наоборот
- Решение сложных задач на больших датасетах позволяет получать хорошие результаты и на маленьких выборках