Материалы кафедры ММП факультета ВМК МГУ. Введение в глубокое обучение.

Занятие 17. Трансформеры

Занятие провел: Ким Роман (@karman_rim)

Материалы составили: Алексеев Илья (@voorhs), Ким Роман (@karman_rim)

Москва, Весенний семестр 2026

Источники:

- **Attention**: Ashish Vaswani et al., 2017, примерно 244 тысяч цитирований
- **FlashAttention**: Tri Dao et al., 2022, примерно 5 тысяч цитирований

Сегодня мы разберём архитектуру **трансформера**, предложенную в работе *Attention Is All You Need* (Vaswani et al., 2017). На момент весны 2025 года у этой статьи более **230000+ цитирований** – это одна из самых влиятельных работ в истории машинного обучения, определившая облик практически всех современных языковых моделей.

Какую задачу мы решаем?

В NLP существует широкий класс задач, где на вход подаётся одна последовательность, а на выход нужно получить другую. Такие задачи называют **sequence-to-sequence** (seq2seq):

- **Машинный перевод**: "The cat sat on the mat" $\longrightarrow$ "Кот сидел на коврике"
- **Суммаризация текста**: длинный документ $\longrightarrow$ краткое изложение
- **Диалоговые системы**: реплика пользователя $\longrightarrow$ ответ модели

Ключевая трудность в том, что входная и выходная последовательности, как правило, имеют **разную длину** и **разную структуру** (например, разные языки с разным порядком слов). Поэтому нельзя просто применить одну и ту же сеть «поэлементно».

Естественная идея – разделить модель на две части:

1. **Кодировщик (encoder)**: читает входную последовательность целиком и сжимает её в набор векторных представлений.
2. **Декодировщик (decoder)**: опираясь на эти представления, порождает выходную последовательность токен за токеном.

Именно эта архитектура «кодировщик–декодировщик» лежит в основе seq2seq моделей. На прошлой лекции вы видели, как она реализуется с помощью RNN. Однако у RNN есть ряд существенных проблем:

- **Последовательные вычисления.** Скрытое состояние h_t зависит от h_{t-1}, поэтому шаги нельзя считать параллельно. Это плохо ложится на архитектуру GPU, которые рассчитаны на массивный параллелизм.
- **Затухание и взрыв градиентов.** При обратном распространении через длинную цепочку рекуррентных шагов градиенты многократно умножаются на одни и те же матрицы весов, из-за чего они экспоненциально затухают или взрываются. LSTM и GRU смягчают эту проблему, но не устраняют полностью.
- **Бутылочное горлышко контекста.** В базовом encoder-decoder вся информация о входной последовательности сжимается в единственный вектор h_T. Для длинных предложений этот вектор не способен удержать всё содержание – информация о первых словах «забывается».

Механизм внимания (attention), добавленный поверх RNN, частично решает третью проблему: декодировщик получает прямой доступ ко всем скрытым состояниям кодировщика. Но первые две проблемы остаются. Возникает вопрос: а нельзя ли построить архитектуру **целиком** на механизме внимания, отказавшись от рекуррентности?

Именно так устроен **трансформер**. Сегодня мы пройдём путь от RNN-версии encoder-decoder до трансформера – архитектуры, которая заменяет рекуррентные связи механизмом внимания и за счёт этого обучается быстрее и качественнее.

Вспоминаем RNN

На прошлой лекции вы узнали про принципы работы RNN:

- обучаемые преобразования для обработки последовательностей в рекуррентном режиме
- shared parameters на каждом рекуррентном шаге
- контекстуализация векторных представлений слов

- механизм внимания в автокодировщике как дополнительный механизм памяти помимо рекуррентного вектора контекста

Мы вводили рекуррентную ячейку:

rnn-cell

Она имеет два входа h, x и два выхода h', y:

$$h' = g_h(W_1 x + W_2 h), \quad y = g_y(W_3 h'),$$

Одним из применений была задача seq2seq моделирования с помощью автокодировщика:

rnn-seq2seq

Давайте запишем псевдокод алгоритма работы кодировщика и декодировщика.

Алгоритм "RNN Encoder"

ВХОД:

- $E = [e(w_1), \ldots, e(w_T)] \in \mathbb{R}^{T \times d}$

ВЫХОД:

- $Y = [y_1, \ldots, y_T] \in \mathbb{R}^{T \times d}$
- $H = [h_1, \ldots, h_T] \in \mathbb{R}^{T \times d}$

---

1. $h_0 := 0$.
2. **Для** t от 1 до T:
   - $h_t, y_t := \mathrm{RNNCell}(h_{t-1}, e(w_t))$.

В алгоритме декодировщика используются так называемые **специальные токены** – выделенные элементы словаря, которые не соответствуют настоящим словам, а управляют поведением модели:

- **BOS** (Beginning Of Sequence) – токен начала последовательности. Подаётся на вход декодировщику как стартовый сигнал: «начинай генерировать».
- **EOS** (End Of Sequence) – токен конца последовательности. Когда декодировщик порождает этот токен, генерация останавливается.
- **PAD** (Padding) – токен-заполнитель. Используется для выравнивания последовательностей разной длины в одном батче до одинаковой длины.

Алгоритм "RNN Decoder" (в режиме обучения)

ВХОД:

- $\tilde{E} = [e(\text{BOS}), e(\tilde{w}_1), \ldots, e(\tilde{w}_{n-1})] \in \mathbb{R}^{n \times d}$
- $h_T \in \mathbb{R}^d$

ВЫХОД:

- $Z = [z_0, z_1, \ldots, z_{n-1}] \in \mathbb{R}^{n \times d}$

---

1. $s_{-1} := h_T$.
2. $e(\tilde{w}_0) := e(\text{BOS})$
3. **Для** t от 0 до $n-1$:
   - $s_t, z_t := \text{RNNCell}(s_{t-1}, e(\tilde{w}_t))$.

Механизм внимания

$$s_t = g_s(W_1 z_t + W_2 s_{t-1} + W_3 c_t), \quad c_t = \sum_{i=1}^{T} h_i \alpha_{it},$$

$$\alpha_{it} = \frac{\exp(\text{sim}(s_{t-1}, h_i))}{\sum_{j=1}^{T} \exp(\text{sim}(s_{t-1}, h_j))}, \quad \text{sim}(x, y) = \text{симметричная функция}.$$

Алгоритм "RNN Decoder с механизмом внимания"

ВХОД:

- $\tilde{E} = [e(\text{BOS}), e(\tilde{w}_1), \ldots, e(\tilde{w}_{n-1}) \in \mathbb{R}^{n \times d}$
- $H = [h_1, h_2, \ldots, h_T] \in \mathbb{R}^{T \times d}$
- $Y = [y_1, \ldots, y_T] \in \mathbb{R}^{T \times d}$

ВЫХОД:

- $Z = [z_0, z_1, \ldots, z_{n-1}] \in \mathbb{R}^{n \times d}$

---

1. $s_{-1} := h_T$.

2. $e(\tilde{w}_0) := e(\text{BOS})$

3. **Для** t от 0 до $n-1$:

   - **Для** i от 1 до T:

$$\alpha_{it} := \frac{\exp(\mathrm{sim}(s_{t-1}, h_i))}{\sum_{j=1}^{T} \exp(\mathrm{sim}(s_{t-1}, h_j))}$$

   - $c_t := \sum_{i=1}^{T} h_i \alpha_{it}$
   - $s_t, z_t := \mathrm{RNNCell}(s_{t-1}, e(\tilde{w}_t), c_t)$.

На этой лекции мы разовьем идею механизма внимания таким образом, что пройдем путь от RNN до трансформера – архитектуры, в которой все рекуррентные связи заменены механизмом внимания.

Механизм внимания в векторной форме

Интуитивно механизм внимания решает задачу: «на какие части входной последовательности сейчас лучше всего смотреть, чтобы принять решение?». Для каждого шага мы берём текущий вектор-состояние (запрос), сравниваем его со всеми скрытыми представлениями (ключами), получаем веса важности и с их помощью усредняем значения.

Проанализируем эти формулы с точки зрения векторных операций. Алгоритм подсчёта атеншена для одного шага следующий:

ВХОД:

- $q \in \mathbb{R}^d$ [запрос, например s_t]
- $K \in \mathbb{R}^{T \times d}$ [ключи, например $h_1, \ldots, h_T$]
- $V \in \mathbb{R}^{T \times d}$ [значения, например $y_1, \ldots, y_T$]

ВЫХОД:

- $c \in \mathbb{R}^d$ [собранный контекст, например c_t]

---

1. $m := Kq$
   Здесь мы считаем скалярные произведения запроса со всеми ключами. Чем больше значение компоненты m_i, тем «похожее» соответствующее скрытое состояние h_i на текущий запрос.
2. $\alpha := \mathrm{Softmax}(m)$
   Применяем Softmax и превращаем сырые «оценки похожести» в вероятностное распределение по позициям (веса важности, которые в сумме дают 1).

3. $c := V^T \alpha$
   Берём взвешенную сумму значений: каждое значение v_i вносит вклад пропорционально своему весу α_i. Полученный вектор c – это «сжатое» представление всей последовательности с учётом текущего запроса.

Операцию, задаваемую этим алгоритмом, обозначим $\mathrm{Attention}(q, K, V)$. Алгоритм декодировщика можно записать так:

---

1. $s_{-1} := h_T$.
2. $e(\tilde{w}_0) := e(\mathrm{BOS})$
3. **Для** t от 0 до $n-1$:
   - $c_t := \mathrm{Attention}(s_{t-1}, H, H)$
   - $s_t, z_t := \mathrm{RNNCell}(s_{t-1}, e(\tilde{w}_t), c_t)$.

Итак, на каждом шаге декодировщик сначала «собирает» из выходов кодировщика релевантный контекст c_t, а уже затем, опираясь на него и на предыдущее состояние, делает предсказание следующего токена. Обратимся к псевдокоду и схеме RNN с атеншеном. Мы видим, что в этом алгоритме есть два способа прокидывания связей между словами: рекуррентные формулы и атеншен пулинг. Идея механизма самовнимания в том, чтобы убрать рекуррентные связи и заменить их атеншен пулингом. Сделаем это аккуратно, распишем отдельно для кодировщика и для декодировщика.

Самовнимание в кодировщике

Идея самовнимания (self-attention) в кодировщике состоит в том, что каждое слово «оглядывается» на всю входную последовательность и строит своё представление как взвешенную смесь других слов. Вместо того чтобы передавать информацию шаг за шагом, как в RNN, мы сразу позволяем каждому токену напрямую взаимодействовать со всеми остальными.

Попытаемся сначала придумать наивный алгоритм, как можно заменить рекуррентные связи на механизм внимания.

ВХОД:

- $E = [e(w_1), \ldots, e(w_T)] \in \mathbb{R}^{T \times d}$

ВЫХОД:

- $Y = [y_1, \ldots, y_T] \in \mathbb{R}^{T \times d}$

- $H = [h_1, \ldots, h_T] \in \mathbb{R}^{T \times d}$

---

1. **Для** t от 1 до T:
   - $c_t := \mathrm{Attention}(e(w_t), E, E)$
   - $y_t := \mathrm{FC}(c_t)$.

В данном случае мы заменили $\mathrm{RNNCell}$ на связку $\mathrm{Attention} + \mathrm{FC}$. То есть, для каждого слова мы сначала собираем контекст с помощью внимания, а затем прогоняем его через небольшой полносвязный блок, чтобы получить новое представление слова.

Мы успешно заменили рекуррентные связи в кодировщике. Принципиальное достоинство этого алгоритма в следующем: каждое слово в последовательности (кодировщика или декодировщика) имеет непосредственную связь со всеми другими словами в этой последовательности (а не как было в RNN: связь с непосредственными соседями). Т.е. последовательность "смотрит" на саму себя, отсюда название алгоритма.

Далее, ключевая идея в том, чтобы обнаружить пространство для оптимизации: заметьте, что все итерации цикла можно посчитать независимо. В функцию $\mathrm{Attention}$ можно подать в качестве q не один вектор $e(w_t)$, а сразу всю последовательность E. В алгоритме атеншена изменится лишь то, что вместо умножения $Kq \in \mathbb{R}^T$ будет умножение $QK^T \in \mathbb{R}^{T \times T}$.

Интерпретировать матрицу QK^T удобно как «карту внимания»: элемент на позиции (t, i) показывает, насколько токен на позиции t обращает внимание на токен на позиции i.

ВХОД:

- $Q \in \mathbb{R}^{T \times d}$
- $K \in \mathbb{R}^{T \times d}$
- $V \in \mathbb{R}^{T \times d}$

ВЫХОД:

- $C \in \mathbb{R}^{T \times d}$

---

1. $m := QK^T / \sqrt{d}$
   Масштабируемое скалярное произведение: считаем все «оценки похожести» между запросами и ключами сразу для всей последовательности.

2. $A := \mathrm{Softmax}(m)$ [построчно]
   Преобразуем оценки в распределение внимания для каждой позиции.
3. $C := AV$
   Собираем новые представления токенов как взвешенные суммы значений.

Если записывать коротко:

$$\mathrm{Attention}(Q, K, V) = \mathrm{Softmax}(QK^T)V.$$

Полный алгоритм кодировщика тогда следующий:

ВХОД:

- $E = [e(w_1), \ldots, e(w_T)] \in \mathbb{R}^{T \times d}$

ВЫХОД:

- $Y = [y_1, \ldots, y_T] \in \mathbb{R}^{T \times d}$

---

1. $C := \mathrm{Attention}(E, E, E)$
2. $Y := \mathrm{FC}(C)$.

Таким образом кодировщик трансформера можно понимать как «слой, который переосмысляет каждое слово с учётом всех остальных слов в предложении». На схеме ниже это и изображено:

Самовнимание в декодировщике

В декодировщике идея похожа: каждое предсказанное слово смотрит на всю уже сгенерированную последовательность и на выходы кодировщика. Разница в том, что теперь мы должны соблюдать причинность: модель не имеет права «заглядывать в будущее», когда предсказывает следующий токен.

Как сделать все то же самое в декодировщике? Наивно, это можно сделать так:

ВХОД:

- $\tilde{E} = [e(\mathrm{BOS}), e(\tilde{w}_1), \ldots, e(\tilde{w}_{n-1})] \in \mathbb{R}^{n \times d}$
- $H = [h_1, h_2, \ldots, h_T] \in \mathbb{R}^{T \times d}$
- $Y = [y_1, \ldots, y_T] \in \mathbb{R}^{T \times d}$

ВЫХОД:

- $Z = [z_0, z_1, \ldots, z_{n-1}] \in \mathbb{R}^{n \times d}$

---

1. $e(\tilde{w}_0) := e(\text{BOS})$
2. **Для** t от 0 до $n-1$:
   - $s_t := \text{Attention}(e(\tilde{w}_t), \tilde{E}, \tilde{E})$ [самовнимание]
   - $c_t := \text{Attention}(s_t, H, Y)$ [кросс-внимание]
   - $z_t := \text{FC}(c_t)$.

Здесь самовнимание позволяет каждому выходному токену учитывать уже сгенерированную часть предложения, а кросс-внимание – «подглядывать» в зашифрованное представление входного предложения (выходы кодировщика).

Первое, что мы можем улучшить, это добавить параллелизм, поскольку итерации цикла независимы:

ВХОД:

- $\tilde{E} = [e(\text{BOS}), e(\tilde{w}_1), \ldots, e(\tilde{w}_{n-1})] \in \mathbb{R}^{n \times d}$
- $H = [h_1, h_2, \ldots, h_T] \in \mathbb{R}^{T \times d}$
- $Y = [y_1, \ldots, y_T] \in \mathbb{R}^{T \times d}$

ВЫХОД:

- $Z = [z_0, z_1, \ldots, z_{n-1}] \in \mathbb{R}^{n \times d}$

---

1. $S := \text{Attention}(\tilde{E}, \tilde{E}, \tilde{E})$
2. $C := \text{Attention}(S, H, Y)$
3. $Z := \text{FC}(C)$.

Отлично! Вы помните, что помимо самовнимания в декодировщике ещё используется внимание, обращённое к выходам кодировщика. В контексте трансформеров это внимание называют кросс-вниманием, т.е. одна последовательность "смотрит" на другую.

Вопрос: в чём проблема этого алгоритма? Почему при обучении он будет показывать почти идеальное качество, но на практике окажется бесполезным? Подсказка: подумайте, какую информацию содержит активация z_t и что по ней мы хотим предсказать.

Ответ:

Правда этот алгоритм ничему полезному не обучится. Надо вспомнить, что декодировщик учится на задачу Causal Language Modeling. В строке 1 самовнимание работает на всю последовательность и в обе стороны, прямо как в кодировщике. Это означает, что в активации z_t, по которой мы планируем делать предсказание токена $\tilde{w}_{t+1}$, уже будет содержаться информация о $e(\tilde{w}_{t+1})$. Происходит **утечка меток**: модель видит правильный ответ до того, как должна его предсказать. На обучении лосс будет стремиться к нулю, но модель просто научится «копировать» следующий токен из входа, а при генерации, когда будущих токенов ещё нет, она не сможет ничего предсказать.

Чтобы этого избежать, вводят маскированное внимание – модель может смотреть только на текущую и предыдущие позиции. Назовем следующий алгоритм операцией $\mathrm{MaskedAttention}(Q, K, V)$.

ВХОД:

- $Q \in \mathbb{R}^{T \times d}$
- $K \in \mathbb{R}^{T \times d}$
- $V \in \mathbb{R}^{T \times d}$

ВЫХОД:

- $C \in \mathbb{R}^{T \times d}$

---

1. $m := QK^T / \sqrt{d}$
2. $m := \mathrm{triu}(m, -\infty)$ [обнуляем (точнее, зануляем логиты до $-\infty$) в верхнем треугольнике матрицы, запрещая смотреть в будущее]
3. $A := \mathrm{Softmax}(m)$ [построчно]
4. $C := AV$

Таким образом, маска обеспечивает причинность: при вычислении внимания для позиции t модель учитывает только позиции $\leq t$.

Вопрос: в текущем алгоритме внимания $\mathrm{sim}(x, y) = \langle x, y \rangle$ – фиксированная функция без обучаемых параметров. Почему это делает модель недостаточно гибкой? Сколько обучаемых параметров у механизма внимания сейчас? Как можно это исправить, не усложняя сильно вычисления?

Ответ:

Текущая модель не содержит обучаемых операций, значит мы можем сделать модель

более гибкой, добавив обучаемые параметры.

Обучаемое внимание

До сих пор мы рассматривали внимание как «жёсткую» операцию, где похожесть между векторами измеряется просто скалярным произведением. Однако в реальных моделях важно, чтобы сама метрика похожести и способы извлечения информации из векторов были обучаемыми – тогда модель сможет подстраиваться под задачу.

В оригинальном атеншене для рекуррентных сетей были обучаемые параметры. Они были зашиты в функции $\mathrm{sim}(x, y) = \mathrm{FC}(x, y)$ – полносвязной сети, которая принимает на вход конкатенацию x и y. Это делает операцию атеншен пулинга обучаемой, что добавляет гибкости и репрезентативной мощности архитектуре в целом. В введённом нами алгоритме используется $\mathrm{sim}(x, y) = \langle x, y \rangle$. Как можно было бы ввести обучаемые параметры в неё, не усложняя сильно вычисления?

Простой и эффективный трюк: перед тем как считать внимание, мы пропускаем входные векторы через обучаемые линейные преобразования. Разные матрицы соответствуют трём ролям векторов – запросам (query), ключам (key) и значениям (value):

$$\mathrm{SelfAttention}(X) = \mathrm{Attention}(XW_q, XW_k, XW_v),$$
$$\mathrm{CrossAttention}(X, Y) = \mathrm{Attention}(XW_q, YW_k, YW_v),$$

где $W_q, W_k, W_v \in \mathbb{R}^{d \times d}$.

Интуитивно это значит, что модель учится: (1) понимать как устроено хорошее «пространство запросов», (2) кодировать «поисковый индекс» (ключи) и (3) хранить полезную информацию (значения). Всё остальное – стандартный механизм внимания, уже работающий в этих новых пространствах.

Нормализация и skip-connection

Один только механизм внимания недостаточен для стабильного обучения глубоких моделей. На практике трансформеры почти всегда дополняют двумя строительными блоками: остаточными связями (skip-connections) и нормализацией (обычно LayerNorm). Они помогают градиенту хорошо протекать по сети и стабилизируют распределения активаций.

ВХОД:

- $X = [x_1, \ldots, x_T] \in \mathbb{R}^{T \times d}$

ВЫХОД:

- $Y = [y_1, \ldots, y_T] \in \mathbb{R}^{T \times d}$

---

1. $C := \mathrm{LayerNorm}(X + \mathrm{SelfAttention}(X))$
   Здесь X складывается с результатом самовнимания (остаточная связь), а затем нормализуется по признаковому измерению.
2. $Y := \mathrm{LayerNorm}(C + \mathrm{FC}(C))$
   Аналогичный приём для полносвязного блока: добавляем вход к выходу и снова нормализуем.

Интуитивно skip-connection говорит модели: «если новый слой не нужен, можно просто пропустить изменение и оставить старое представление», а нормализация не даёт активациям «разбегаться» по масштабу. Вместе это делает обучение гораздо более устойчивым даже для десятков и сотен слоёв.

У декодировщика ситуация аналогичная, только между самовниманием и полносвязным блоком появляется ещё кросс-внимание.

ВХОД:

- $\tilde{X} = [\tilde{x}_1, \ldots, \tilde{x}_T] \in \mathbb{R}^{T \times d}$
- $Y = [y_1, \ldots, y_T] \in \mathbb{R}^{T \times d}$

ВЫХОД:

- $\tilde{Y} = [\tilde{y}_1, \ldots, \tilde{y}_T] \in \mathbb{R}^{T \times d}$

---

1. $S := \mathrm{LayerNorm}(\tilde{X} + \mathrm{MaskedSelfAttention}(\tilde{X}))$
2. $S := \mathrm{LayerNorm}(S + \mathrm{CrossAttention}(S, Y))$
3. $\tilde{Y} := \mathrm{LayerNorm}(S + \mathrm{FC}(S))$

Такой «слой-трансформер» (attention + FFN + остаточные связи + нормализация) и является основным строительным элементом современных моделей.

Вычислительная сложность трансформера

Трансформер часто представляют как «дорогую» модель, и это верно, если смотреть

на асимптотику: внимание требует работы с матрицами размера $T \times T$, где T – длина последовательности. Но при этом трансформеры прекрасно загружают GPU и выигрывают за счёт параллелизма.

Если взглянуть на псевдокод RNN и посчитать число операций и потребление памяти, то получится $O(T)$, где T – длина последовательности. У трансформера в механизме внимания возникает перемножение матриц QK^T, поэтому сложность трансформера и потребление памяти $O(T^2)$.

Как так? Мы получили, что новая архитектура поедает колоссально много ресурсов, особенно в случае экстра длинных последовательностей. Однако может показаться парадоксом, но за одно и то же время трансформер способен пройти большее число шагов оптимизации, чем RNN. Дело в том, что в алгоритме RNN присутствует цикл по t, т.е. алгоритм принципиально последовательный, а такое медленно считается на GPU. В трансформере же всё сведено к матричному перемножению – эта операция эффективно параллелизуется на GPU и позволяет утилизировать больше вычислительной мощности. Т.е. трансформеру действительно нужно сделать больше операций с вещественными числами, но эти операции намного быстрее.

Это объясняется архитектурными особенностями GPU:

- SIMD: single instruction multiple data – одна инструкция применяется сразу к большому числу элементов.
- Иерархия памяти: важна локальность доступа к данным, чтобы реже «промахиваться» по кешу.
- High-throughput, а не low-latency: GPU лучше всего работает, когда мы даём ему много одинаковой работы сразу (как в матричных операциях), а не маленькие последовательные шаги.

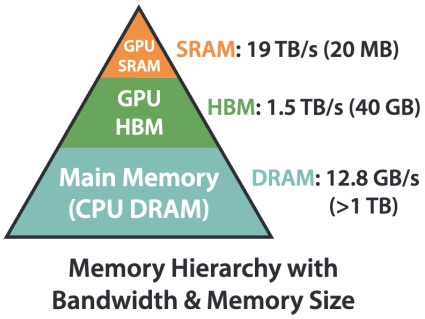

Источник

Однако существует много архитектурных приёмов ускорения трансформеров. Почти все они направлены на эффективное вычисление и хранение матриц внимания (пример: разреженное внимание, низкоранговые аппроксимации, кэширование ключей и значений в декодере и т.п.).

Многоголовочность

Обычное (одноголовое) внимание уже даёт модели возможность гибко комбинировать информацию по последовательности. Но на практике оказалось полезным считать несколько разных «видов внимания» параллельно – это и есть многоголовочное внимание (multi-head attention).

Идея в том, что мы разбиваем исходное пространство признаков на несколько подпространств меньшей размерности и в каждом из них считаем своё внимание. Каждая голова может специализироваться на своём типе зависимостей: одна – на синтаксисе, другая – на длинных зависимостях, третья – на редких словах и т.д.

$$\mathrm{head}_i = \mathrm{Attention}(Q\underbrace{W_q}_{d\times\frac{d}{n}}, K\underbrace{W_k}_{d\times\frac{d}{n}}, V\underbrace{W_v}_{d\times\frac{d}{n}}) \in \mathbb{R}^{T\times\frac{d}{n}}, \quad i = \overline{1,n},$$

$$\mathrm{MultiHeadAttention}(Q,K,V) = \mathrm{concat}(\mathrm{head}_1,\ldots,\mathrm{head}_n)\underbrace{W_o}_{d\times d}$$

Благодаря этому механизму возникает несколько эффектов:

- **Ансамблирование**: несколько «точек зрения» на одну и ту же последовательность, которые затем объединяются.
- **Узкое горлышко**: каждая голова работает в меньшем пространстве d/n, что ограничивает её ёмкость и заставляет головы специализироваться.
- **Ещё больше параллелизма**: все головы считаются независимо и одновременно, что хорошо ложится на архитектуру GPU.

В сумме многоголовочность делает слой внимания гораздо более выразительным при умеренном увеличении числа параметров.

Полносвязный блок

Помимо внимания в каждом слое трансформера есть ещё один важный компонент – position-wise feed-forward сеть (полносвязный блок). Она применяется независимо к каждому токену (одни и те же веса для всех позиций) и отвечает за «нелинейную обработку» уже собранного контекста.

Блок position wise feed forward обладает одинаковой структурой почти во всех трансформерах: это двухслойная сеть, которая из активации размерности d получает активацию размерности $4d$ и затем обратно d.

$$\mathrm{FC}(X) := g(X \underbrace{W_1}_{d \times 4d} + b_1) \underbrace{W_2}_{4d \times d} + b_2.$$

Смысл такой архитектуры двоякий:

- **Мягкий словарь.** Эти блоки составляют подавляющую часть всех параметров трансформера. Логично предположить, что в них хранится большая часть знаний трансформера как языковой модели о внешнем мире.
- **Утилизация GPU.** Такие сети называют широкими. Мы можем противопоставить ей глубокую сеть: что если взять полносвязную сеть с тем же числом параметров, но сделать много узких слоёв вместо двух широких? Эта архитектура плоха по той же причине, почему плох RNN: лучше использовать одну большую, но параллелизуемую операцию, чем много маленьких, но последовательных.

В оригинальном трансформере и в целом в трансформерах долгое время использовались функции активации наподобие ReLU и GELU. Сейчас всё чаще используются SwiGLU (особенно в LLM):

1. $h_1 := XW_1 + b_1$ [расширение $d \to 4d$]
2. $h_2 := XW_2 + b_2$ [расширение $d \to 4d$]
3. $h_{\mathrm{SwiGLU}} := h_1 \circ \sigma(h_1) \circ h_2$ [размерность $4d$]
4. $\mathrm{FC}(X) := h_{\mathrm{SwiGLU}} W_3 + b_3$ [сужение $4d \to d$]

Интуитивно SwiGLU даёт более гибкую и плавную нелинейность, чем ReLU, и лучше подходит для очень больших языковых моделей, улучшая качество при сопоставимых затратах.

Позиционная кодировка

Заметим одну примечательную особенность: атеншен обрабатывает множество, а не последовательность. В рекуррентных сетях порядок слов учитывался в самом алгоритме за счёт использования цикла по t. Сейчас же мы имеем только перемножение матриц, порядок слов отражается только в порядке строк в этих матрицах, но не в самих признаках. В текущем виде информация о порядке слов нигде не учитывается.

Чтобы модель понимала, где в предложении находится каждое слово, вводят **позиционную кодировку**. Идея в том, чтобы ко входным эмбедингам слов добавлять специальный эмбединг, соответствующий номеру слова в предложении. Тогда даже два одинаковых слова, стоящих в разных местах, будут иметь разные суммарные векторы «эмбединг + позиция».

Оригинальный трансформер использовал фиксированные эмбединги, получаемые с помощью синусов и косинусов. Затем сообщество открыло, что эти эмбединги можно просто инициализировать случайными и обучать. Сейчас продвинутые трансформеры

вообще отошли от этой идеи и используют методы, которые напрямую влияют на механизм подсчёта атеншена (rotary embeddings, ALiBi и др.).

Синусоидная кодировка состоит в том, чтобы завести матрицу $P \in \mathbb{R}^{T \times d}$, где T – максимальная длина последовательностей, которые наша модель будет поддерживать. Матрица определяется следующими правилами:

$$P_{m,2i} := \sin\left(\frac{m}{10000^{2i/d}}\right), \quad P_{m,2i+1} := \cos\left(\frac{m}{10000^{2i/d}}\right),$$

для всех $i = \overline{1, d/2}$.

Такая форма выбрана так, чтобы близкие по позиции токены имели близкие кодировки, а модель могла обобщать на длины последовательностей, которых не видела при обучении.

Полная схема трансформера

На этой схеме собраны вместе все элементы, которые мы обсудили: самовнимание, кросс-внимание, многоголовочность, позиционные кодировки, полносвязные блоки, нормализация и остаточные связи. Кодировщик последовательно применяет несколько одинаковых слоёв к входной последовательности, а декодировщик – к выходной, дополнительно заглядывая в представления кодировщика через кросс-внимание.

Важно понимать, что трансформер – это не «магическая чёрная коробка», а композиция простых по отдельности блоков. Схема лишь показывает, как именно эти блоки соединены между собой.

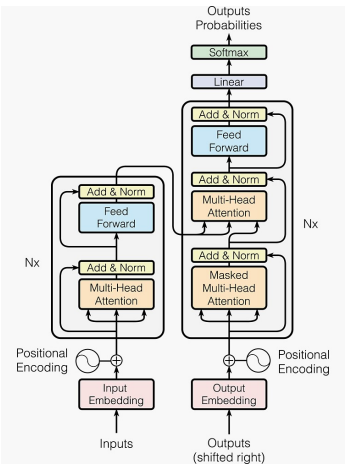

Источник